

UNIVERSIDADE FEDERAL DO CEARÁ

CAMPUS RUSSAS

ARTIGO CIENTÍFICO E RELATÓRIO DE IMPLEMENTAÇÃO

JOAO PEDRO SCHONTZ DA SILVA — 555036

LUCAS DE SOUZA ALMEIDA — 569990

EXPLICABILIDADE LOCAL E GLOBAL EM APRENDIZADO FEDERADO NÃO-IID: UM ESTUDO COM DADOS DE SENSORES DISTRIBUÍDOS

Docente: PITAGORAS GRAÇA MARTINS

RUSSAS — CE

2026

EXPLICABILIDADE LOCAL E GLOBAL EM APRENDIZADO FEDERADO NÃO-IID: UM ESTUDO COM DADOS DE SENSORES DISTRIBUÍDOS

JOAO PEDRO SCHONTZ DA SILVA[1]; LUCAS DE SOUZA ALMEIDA[2]

Universidade Federal do Ceará — Campus Russas

Docente: PITAGORAS GRAÇA MARTINS

[1] Matrícula: 555036. [2] Matrícula: 569990.

RESUMO

O aprendizado federado permite treinar modelos de maneira colaborativa a partir de conjuntos de dados mantidos em diferentes clientes. Entretanto, diferenças nas distribuições locais de classes e características podem afetar o desempenho preditivo e a interpretação das decisões. Este trabalho investiga a explicabilidade local e global em cenários não independentes e identicamente distribuídos (Não-IID), com foco em características relacionadas a sensores. São discutidos FedAvg, FedProx e Integrated Gradients, além de um protocolo comparativo e de uma aplicação reproduzível em Python. O sistema realiza particionamento de dados, treinamento centralizado e federado, avaliação por acurácia e Macro-F1, cálculo de atribuições e visualização de resultados. Foram conduzidas três execuções com dados sintéticos, cujas métricas, gráficos e comparações compõem a análise experimental. A aplicação inclui suporte à preparação do conjunto UCI Human Activity Recognition para estudos posteriores.

Palavras-chave: aprendizado federado; dados Não-IID; explicabilidade; sensores; Integrated Gradients.

ABSTRACT

Federated learning enables collaborative training with data distributed across multiple clients. However, differences in local class and feature distributions can affect predictive performance and model interpretation. This work examines local and global explainability under non-independent and identically distributed (non-IID) conditions, focusing on sensor-related features. FedAvg, FedProx, and Integrated Gradients are discussed within a comparative experimental protocol and a reproducible Python application. The software supports data partitioning, centralized and federated training, accuracy and macro-F1 evaluation, feature attribution, and a dashboard for exploring results. Three experiments using synthetic data were conducted, and their metrics, figures, and comparisons are analyzed. The application also provides a data-loading workflow for subsequent experiments with the UCI Human Activity Recognition dataset.

Keywords: federated learning; non-IID data; explainable AI; sensors; Integrated Gradients.

1 INTRODUÇÃO

A disseminação de sensores embarcados em smartphones e dispositivos vestíveis ampliou a disponibilidade de séries temporais relacionadas a movimentos e atividades

cotidianas. Dados dessa natureza podem apoiar tarefas de classificação, mas frequentemente são produzidos por pessoas e dispositivos diferentes, com comportamentos, condições de uso e distribuições desiguais. Em situações nas quais os dados não podem ou não devem ser reunidos em um único repositório, o aprendizado federado constitui uma forma de organizar o treinamento colaborativo de modelos (MCMAHAN et al., 2017).

Ao contrário da hipótese idealizada de que todas as amostras têm a mesma distribuição, cenários federados podem apresentar heterogeneidade de rótulos, de características ou da quantidade de exemplos disponíveis por participante. Esse fenômeno, frequentemente referido como Não-IID, interfere na otimização e pode produzir comportamentos diferentes entre clientes. Li et al. (2020) discutem a heterogeneidade no contexto da otimização federada e propõem o FedProx como uma alternativa ao treinamento local convencional.

O desempenho de classificação, isoladamente, não permite compreender quais características influenciam as decisões do modelo. Técnicas de inteligência artificial explicável oferecem maneiras de examinar atribuições por entrada e padrões agregados de importância. Entretanto, uma diferença de explicações entre clientes pode refletir tanto a natureza dos dados quanto mudanças efetivas no comportamento do modelo; é necessário planejar comparações controladas antes de interpretar essas diferenças como erro, instabilidade ou falta de confiança.

Este trabalho integra três componentes: um recorte de revisão bibliográfica; um protocolo de experimentação com diferentes distribuições de dados; e a implementação de um ambiente de simulação e análise. O objeto central não é apresentar um algoritmo de aprendizado federado inédito, mas organizar uma avaliação reproduzível da relação entre heterogeneidade estatística, desempenho e explicabilidade.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Aprendizado federado

Em um procedimento federado, um servidor inicializa um modelo global e disponibiliza seus parâmetros aos clientes participantes. Cada cliente realiza treinamento local sobre seus dados e devolve parâmetros ou atualizações para agregação. O procedimento é repetido ao longo de rodadas de comunicação. No FedAvg, a agregação é ponderada pela quantidade de exemplos de cada cliente, conforme a expressão $w(t+1) = \Sigma k\ [nk / N] \cdot wk(t+1)$, em que nk é o tamanho do conjunto local e N corresponde à soma de exemplos dos clientes participantes (MCMAHAN et al., 2017).

Esse mecanismo reduz a necessidade de centralizar dados brutos, mas não elimina, por si só, riscos de inferência a partir de atualizações.

2.2 Heterogeneidade estatística e dados Não-IID

Uma distribuição é denominada IID quando as observações podem ser tratadas como independentes e oriundas de uma mesma distribuição. Em aplicações federadas, essa hipótese muitas vezes não se sustenta: participantes podem executar atividades distintas, possuir sensores com características diferentes ou registrar quantidades desiguais de exemplos. A heterogeneidade pode manifestar-se, entre outros casos, como desbalanceamento de classes ou deslocamento das distribuições de características.

Para estudar separadamente o efeito do particionamento, um procedimento recorrente utiliza uma distribuição Dirichlet para definir a proporção de amostras de cada classe alocadas aos clientes. Valores menores do parâmetro alfa geralmente produzem maior concentração de classes, embora a severidade efetiva deva ser verificada na distribuição final. O fato de os dados estarem separados por indivíduo, por si só, não comprova um nível específico de heterogeneidade.

2.3 FedAvg e FedProx

O FedAvg atualiza os modelos locais por otimização convencional e posteriormente combina os parâmetros. O FedProx acrescenta à função de perda local um termo proximal, proporcional à distância quadrática entre os parâmetros locais e os parâmetros globais recebidos na rodada. Sua formulação pode ser descrita como $Fk(w) + (\mu/2) ||w - wt||^2$, em que μ controla a penalização (LI et al., 2020). Esse mecanismo representa uma possibilidade de reduzir derivações excessivas entre atualizações locais, mas seus ganhos não são universais e dependem dos dados, do modelo e do ajuste experimental.

2.4 Explicabilidade local e global

Uma explicação local descreve a contribuição de características para determinada previsão. Já uma explicação global sintetiza padrões de comportamento do modelo sobre um conjunto de observações. Os termos “local” e “global”, nesse contexto, descrevem o alcance da explicação e não devem ser confundidos, respectivamente, com o modelo armazenado no cliente e com os parâmetros agregados pelo servidor.

SHAP, apresentado por Lundberg e Lee (2017), é uma referência importante para a atribuição de importância a características. O protótipo deste trabalho, entretanto, implementa Integrated Gradients, técnica descrita por Sundararajan, Taly e Yan (2017), que integra os

gradientes da saída do modelo ao longo de um caminho entre uma referência e a entrada observada. Nesse caso, as atribuições são calculadas para o logit da classe prevista e uma referência nula após a padronização; a importância global corresponde à média do módulo das atribuições nas amostras selecionadas. A interpretação depende tanto da referência escolhida quanto do conjunto de observações explicado.

2.5 Dados de sensores e reconhecimento de atividades

O conjunto Human Activity Recognition Using Smartphones (UCI HAR) reúne características derivadas de acelerômetro e giroscópio de smartphones para reconhecimento de atividades humanas. A disponibilização de uma partição oficial por participantes torna esse conjunto adequado para avaliação de generalização em indivíduos não vistos. O uso de características já extraídas dos sinais, contudo, é diferente da explicação direta de amostras brutas de séries temporais; tal distinção deve constar na interpretação dos resultados.

3 TRABALHOS RELACIONADOS E REVISÃO DA LITERATURA

A seleção inicial de trabalhos considera bases conceituais para o treinamento federado, a heterogeneidade e a explicabilidade. Os estudos abaixo não representam um levantamento sistemático exaustivo da produção recente: são referências fundamentais para estruturar a avaliação e orientar uma busca bibliográfica ampliada.

Referência	Contribuição considerada	Relação com a pesquisa
McMahan et al. (2017)	Define o procedimento FedAvg.	Base da agregação federada.
Li et al. (2020)	Discute otimização sob heterogeneidade; FedProx.	Alternativa de treinamento comparativa.
Lundberg e Lee (2017)	Apresenta SHAP.	Referência conceitual em atribuições.
Sundararajan et al. (2017)	Descreve Integrated Gradients.	Método de XAI efetivamente implementado.
Kairouz et al. (2021)	Organiza desafios e problemas em aberto de FL.	Contextualização metodológica e limitações.
Anguita et al. (2013)	Apresenta dados de atividades humanas em smartphones.	Domínio de aplicação com sensores.

Um levantamento bibliográfico aprofundado poderá utilizar combinações de “federated learning”, “non-IID”, “sensor data”, “human activity recognition”, “explainability” e “feature attribution” em fontes como ACM Digital Library, IEEE Xplore, Scopus e Google Scholar. Em cada busca, deverão ser registrados a base, a data, a expressão empregada, o total de resultados, os critérios de inclusão e exclusão e os motivos de descarte. Essa etapa permitirá verificar se a questão específica da concordância entre explicações já foi respondida em trabalhos anteriores, evitando afirmações de originalidade sem suporte.

A possibilidade de contribuição científica delineada é uma análise experimental conjunta do desempenho preditivo e da variação das atribuições de características quando muda o perfil estatístico dos clientes. A efetiva novidade desse recorte dependerá da revisão aprofundada de artigos recentes, ainda não realizada neste trabalho.

4 PROBLEMA E OBJETIVOS

4.1 Problema de pesquisa

Como diferentes distribuições de dados entre clientes, representadas por cenários IID e Não-IID, afetam o desempenho e as explicações locais e globais de classificadores treinados de maneira federada em características provenientes de sensores?

4.2 Objetivo geral

Estruturar e operacionalizar uma investigação reproduzível sobre a relação entre heterogeneidade estatística, desempenho de classificação e explicabilidade em modelos federados aplicados a dados de sensores.

4.3 Objetivos específicos

- Descrever abordagens existentes de treinamento federado e atribuição de importância a características.
- Definir cenários controlados de distribuição de dados e estabelecer conjuntos de treino, validação e teste sem sobreposição de participantes.
- Implementar e comparar os métodos centralizado, FedAvg e FedProx sob parâmetros explicitados.
- Produzir atribuições para previsões individuais e medidas agregadas de importância global.
- Examinar concordância entre características mais relevantes de métodos e clientes.
- Disponibilizar uma aplicação demonstrativa e um protocolo de reprodução dos experimentos.

4.4 Questões de pesquisa e hipóteses

QP1: como as alterações na distribuição das classes entre clientes se relacionam às métricas de classificação? QP2: como as importâncias globais variam entre FedAvg, FedProx e uma referência centralizada? QP3: qual é o grau de concordância das características consideradas relevantes pelos modelos quando avaliadas em diferentes clientes?

As hipóteses operacionais são a possibilidade de redução de desempenho sob maior heterogeneidade e de menor concordância entre explicações locais de clientes. Não se pressupõe, entretanto, que tais relações sejam monotônicas ou válidas sem teste estatístico. As hipóteses permanecem abertas até a execução de experimentos com dados reais e múltiplas sementes.

5 MATERIAIS E MÉTODOS

5.1 Delineamento do estudo

O estudo foi organizado como investigação computacional experimental, com avaliação de desempenho e de atribuições de características. Nesta etapa, as execuções utilizaram dados sintéticos gerados pelo próprio projeto, em três sementes aleatórias. O pipeline também dispõe de um carregador para o UCI HAR, cujo conjunto de dados não foi executado nesta versão.

5.2 Dados e estratégia de separação

Os registros utilizados na execução são gerados a partir de doze características que representam médias e desvios de seis eixos hipotéticos de sensores. Quatro classes são atribuídas a observações de participantes artificiais, com variação entre grupos. Treino, validação e teste são separados por identificadores de participante, sem compartilhamento de indivíduos entre os conjuntos. No modo UCI HAR, o carregador mantém a divisão oficial de treino e teste e obtém validação apenas dos participantes de treinamento.

As características são padronizadas com parâmetros ajustados somente sobre o conjunto de treinamento. Nesta implementação, as estatísticas de padronização são calculadas a partir do treino agregado para permitir comparações offline. Um cenário federado com restrições adicionais de privacidade demandaria outro procedimento de pré-processamento.

5.3 Cenários de distribuição

Foram implementados seis clientes simulados e três formas de particionamento controlado por classe: cenário aproximadamente IID ($\alpha = 100$), Não-IID moderado ($\alpha = 0,5$) e Não-IID severo ($\alpha = 0,15$). A classificação verbal dos níveis é uma convenção do experimento: a heterogeneidade deve ser verificada pelas quantidades de classes em cada cliente. Para o UCI HAR também existe uma opção de particionamento natural por participantes, diferente do particionamento Dirichlet. Em todos os casos, clientes recebem conjuntos disjuntos de índices do treinamento.

5.4 Modelos e protocolo de treinamento

A arquitetura de classificação é uma rede neural multicamada (MLP) composta por duas camadas ocultas de 32 e 16 unidades com função de ativação ReLU, seguidas por saída de classificação. O número de entradas e saídas acompanha o dataset. O treinamento utiliza a função de entropia cruzada e o otimizador SGD. O treinamento centralizado usa o conjunto agregado de treino; os métodos federados executam atualizações locais sequenciais e agregação ponderada por tamanho de amostra, sem transferência dos dados brutos entre módulos de clientes e agregador.

Na verificação registrada neste documento, foram utilizadas 15 rodadas, uma época local por rodada, taxa de aprendizado 0,07, lotes de até 64 exemplos, parâmetro proximal $\mu = 0,3$ e sementes 42, 43 e 44. A primeira execução é detalhada individualmente e as três são resumidas por média e desvio-padrão. Todos os métodos iniciam a partir de pesos controlados pela mesma semente. Esses valores não constituem hiperparâmetros universalmente ótimos e não substituem uma etapa posterior de ajuste usando apenas dados de validação.

5.5 Protocolo de explicabilidade

Integrated Gradients é calculado com 16 passos de integração sobre as primeiras 50 amostras do conjunto de teste, usando referência zero no espaço padronizado e logit da classe prevista pelo próprio modelo. Em seguida, calcula-se a média dos valores absolutos de atribuição por característica, gerando uma ordenação global. Para avaliar diferenças entre clientes, também se calculam atribuições sobre até 15 exemplos do conjunto local de treinamento, com 10 passos, de forma explicitamente descritiva. A concordância entre pares de ordenações é quantificada pelo índice de Jaccard entre os conjuntos das cinco características mais relevantes.

O uso dos dados locais de treinamento para descrever características relevantes em cada cliente não permite concluir desempenho de generalização. Um experimento final pode incluir amostras locais de avaliação mantidas fora do treinamento para aumentar a robustez dessa comparação. Também é importante observar que atribuição estatística de características não implica causalidade.

5.6 Métricas e avaliação

Acurácia e Macro-F1 são calculadas sobre o teste não utilizado no treinamento. As séries por rodada registram essas métricas em validação. O índice de Jaccard avalia a sobreposição de características nos respectivos grupos Top-5, variando entre zero e um. A interface lê tabelas produzidas pela execução e não recalcula automaticamente os modelos ao

alterar filtros. Para futuras conclusões quantitativas, o protocolo prevê repetições com diferentes sementes, indicação de dispersão e comparação dos métodos sob orçamentos computacionais declarados.

5.7 Procedimentos de confiabilidade

Os testes automatizados verificam dimensões e organização dos dados, particionamento disjunto, agregação ponderada, formatos de atribuições e execução de uma rodada federada. A aplicação registra configurações em JSON e exporta separadamente métricas, históricos, distribuições e explicações, favorecendo a reprodução dos experimentos.

6 DESENVOLVIMENTO DA APLICAÇÃO PRÁTICA

6.1 Organização do software

O projeto, denominado Federated XAI Lab, foi organizado em módulos para preparação de dados (data.py), modelos preditivos (models.py), treinamento federado e centralizado (federated.py), cálculo de explicabilidade (explanation.py) e execução de experimentos (experiment.py). O arquivo app.py utiliza Streamlit para examinar tabelas e figuras. O pacote inclui documentação, dependências, testes e saídas de execução.

Os componentes de treinamento trabalham com PyTorch; a distribuição dos dados e as métricas utilizam NumPy e scikit-learn; os registros tabulares são exportados por Pandas; e as figuras são produzidas com Matplotlib. A implementação de FedAvg e FedProx foi escrita diretamente em Python/PyTorch, sem dependência de um servidor Flower. O uso futuro do Flower é possível, mas não faz parte do protótipo entregue.

6.2 Fluxo de execução

O processo é iniciado por uma chamada de linha de comando que determina origem dos dados, quantidade de clientes, número de rodadas, parâmetros do treinamento, semente e diretório de resultados. O programa carrega o conjunto de treinamento, cria as partições, executa os três métodos, calcula métricas no teste, produz atribuições e exporta gráficos e tabelas. Ao final, o dashboard permite selecionar um cenário, inspecionar métricas e comparar importâncias globais e acordos entre clientes.

Camada	Módulo / arquivo	Responsabilidade
Dados	src/flxai/data.py	Dados sintéticos, UCI HAR, separações e partições.
Modelo	src/flxai/models.py	MLP de arquitetura compartilhada.
Aprendizado	src/flxai/federated.py	Treino centralizado, FedAvg e FedProx.

Camada	Módulo / arquivo	Responsabilidade
Explicabilidade	src/flxai/explanation.py	Integrated Gradients e rankings.
Execução	src/flxai/experiment.py	Experimentos, métricas, CSV e imagens.
Interface	app.py	Painel de exploração dos resultados.
Validação	tests/test_core.py	Verificações automatizadas básicas.

6.3 Execução dos experimentos

Com Python 3.10 ou superior e as dependências instaladas, os experimentos são executados a partir da pasta principal do projeto. O comando a seguir corresponde à configuração da execução com semente 42. Os detalhes de instalação constam no README.

```
python -m flxai.experiment --mode synthetic --output-dir results/demonstracao --rounds 15 --clients 6 --seed 42 --lr 0.07 --mu 0.3 --xai-samples 50 --ig-steps 16
```

A interface é iniciada com “streamlit run app.py” e carrega os resultados exportados. Para utilizar o conjunto UCI HAR, os arquivos oficiais devem ser obtidos no repositório da UCI e fornecidos ao programa por meio dos parâmetros “--mode uci --dataset-path ...”.

6.4 Arquivos entregues e documentação

A implementação gera metricas.csv, historico_validacao.csv, distribuicao_clientes.csv, importancia_global.csv, atribuicoes_locais.csv, concordancia_top5.csv, importancia_por_cliente.csv, concordancia_entre_clientes.csv, config.json e dataset_info.json. Também salva comparacao_f1.png e importancia_top10.png. O código-fonte, as saídas geradas, o arquivo de dependências e as instruções de execução acompanham o projeto compactado. O arquivo ZIP não inclui os dados oficiais do UCI HAR, sujeitos às condições de distribuição do repositório de origem.

7 RESULTADOS DOS EXPERIMENTOS COMPUTACIONAIS

Esta seção reúne métricas e gráficos obtidos diretamente dos arquivos gerados pelo programa na execução com semente 42. Foram comparadas as estratégias centralizada, FedAvg e FedProx nos três cenários de distribuição definidos na metodologia.

Distribuição	Treinamento	Acurácia	Macro-F1
IID	Centralizado	94,0%	0,930
IID	FedAvg	36,9%	0,301
IID	FedProx	36,2%	0,295
Não-IID moderado	Centralizado	94,0%	0,930
Não-IID moderado	FedAvg	69,6%	0,572

Distribuição	Treinamento	Acurácia	Macro-F1
Não-IID moderado	FedProx	69,6%	0,568
Não-IID severo	Centralizado	94,0%	0,930
Não-IID severo	FedAvg	85,1%	0,812
Não-IID severo	FedProx	83,6%	0,794

A referência centralizada mantém o mesmo resultado nos três cenários porque não utiliza as partições dos clientes. Os métodos federados apresentaram variações entre distribuições e sementes. Na execução com semente 42, o cenário de maior concentração de classes não apresentou a menor Macro-F1, resultado que evidencia a influência conjunta do particionamento e da dinâmica de otimização.

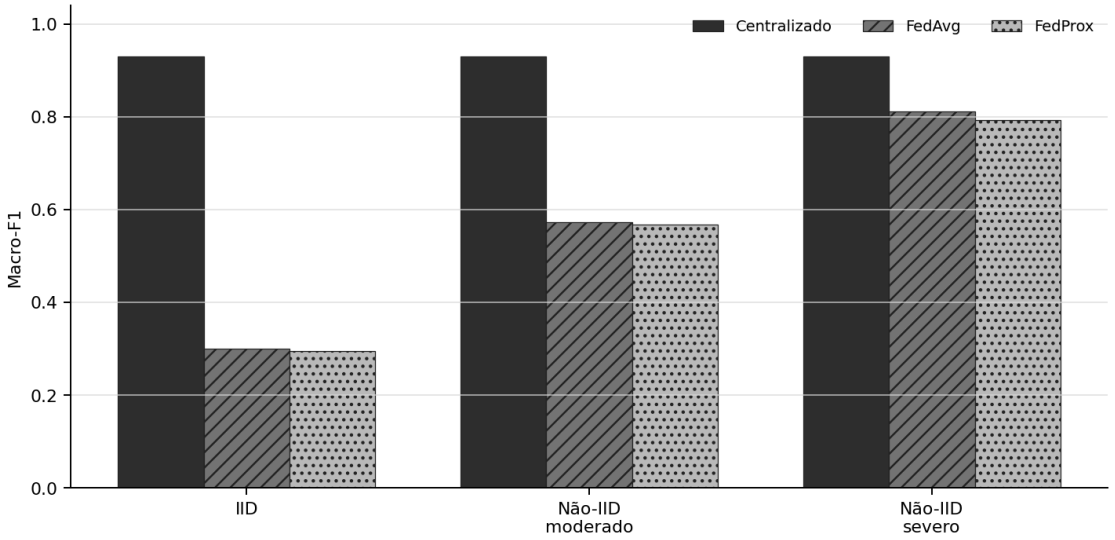


Figura 1 — Macro-F1 por método de treinamento e cenário de distribuição.

Fonte: elaboração própria, a partir dos resultados da execução com semente 42.

O cálculo de Integrated Gradients permitiu ordenar as características pela média absoluta das atribuições. A Figura 2 apresenta os dez atributos com maior importância global no modelo FedAvg para o cenário de maior concentração de classes.

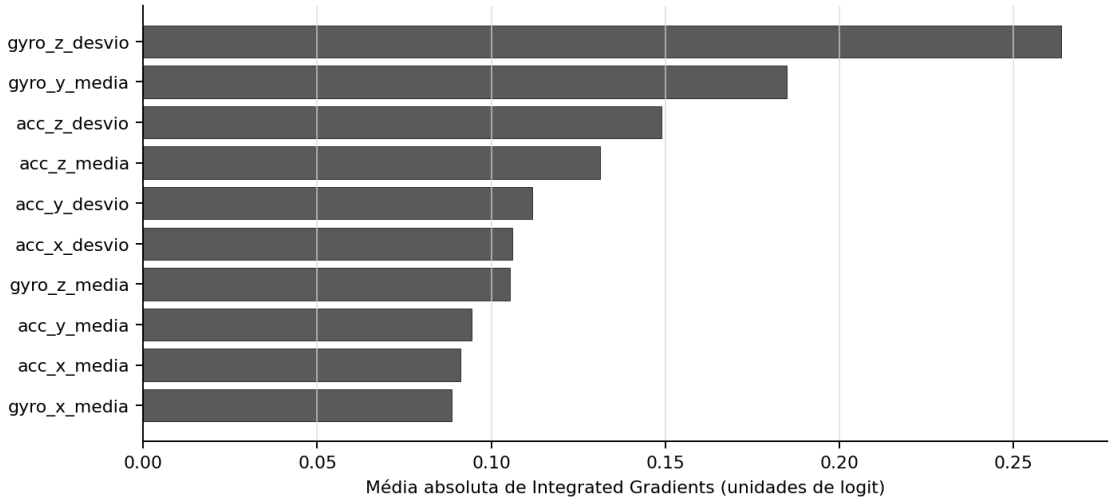


Figura 2 — Importância global das características por Integrated Gradients.

Fonte: elaboração própria, a partir dos resultados da execução com semente 42.

Distribuição	Método	Jaccard médio Top-5
IID	FedAvg	0,570
IID	FedProx	0,570
Não-IID moderado	FedAvg	0,784
Não-IID moderado	FedProx	0,800
Não-IID severo	FedAvg	0,626
Não-IID severo	FedProx	0,626

A concordância entre clientes foi calculada pela interseção média dos cinco atributos de maior importância em seus respectivos subconjuntos. As diferenças observadas refletem tanto a composição das amostras locais quanto o comportamento do modelo, justificando avaliações adicionais com um conjunto de referência comum.

7.1 Síntese de três execuções com sementes distintas

Além da execução inicial com semente 42, o programa foi executado com sementes 43 e 44. Foram mantidos seis clientes, 15 rodadas, uma época local, taxa de aprendizagem de 0,07, $\mu = 0,3$, 50 amostras para explicações globais e 16 passos de integração. Cada semente influencia a geração dos registros, o particionamento e a inicialização, e a dispersão apresentada reflete essas fontes de variabilidade.

Cenário	Treinamento	Macro-F1 (média ± DP)	Acurácia (média ± DP)
IID	Centralizado	0,952 ± 0,021	0,956 ± 0,016
IID	FedAvg	0,404 ± 0,119	0,491 ± 0,107
IID	FedProx	0,398 ± 0,120	0,486 ± 0,108
Não-IID moderado	Centralizado	0,952 ± 0,021	0,956 ± 0,016
Não-IID moderado	FedAvg	0,614 ± 0,046	0,693 ± 0,039
Não-IID moderado	FedProx	0,605 ± 0,036	0,687 ± 0,031

Cenário	Treinamento	Macro-F1 (média ± DP)	Acurácia (média ± DP)
Não-IID severo	Centralizado	0,952 ± 0,021	0,956 ± 0,016
Não-IID severo	FedAvg	0,727 ± 0,170	0,767 ± 0,175
Não-IID severo	FedProx	0,706 ± 0,159	0,753 ± 0,170

DP corresponde ao desvio-padrão amostral, com três execuções por combinação. O treinamento centralizado independe da distribuição entre clientes e, por isso, apresenta a mesma média nos três cenários. A avaliação utiliza conjuntos de teste separados por participante.

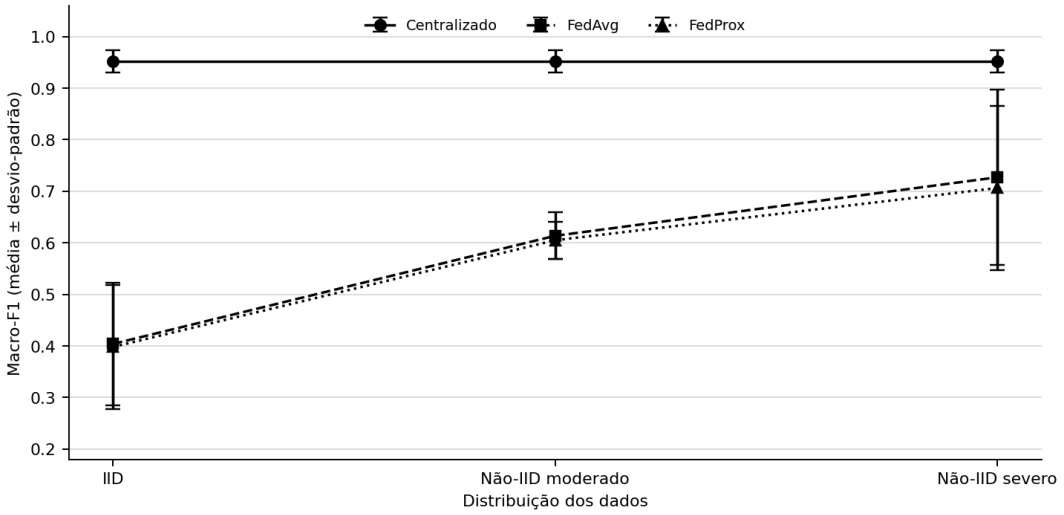


Figura 3 — Macro-F1 nas três execuções: média e desvio-padrão.

Fonte: elaboração própria, com resultados das sementes 42, 43 e 44.

A Macro-F1 média do FedAvg foi 0,404 no cenário aproximadamente IID, 0,614 no Não-IID moderado e 0,727 no Não-IID severo. A dispersão foi maior no último cenário, indicando sensibilidade às condições da execução. A variação observada não apresenta, isoladamente, uma relação causal entre heterogeneidade e desempenho.

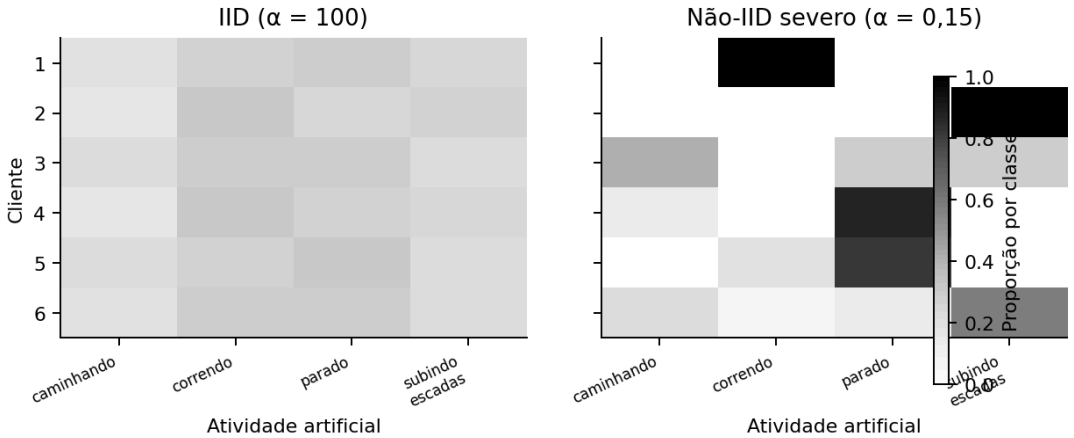


Figura 4 — Proporção das quatro classes entre os seis clientes.

Fonte: elaboração própria, com dados de distribuicao_clientes.csv (semente 42).

A Figura 4 permite observar o efeito das diferentes partições na composição dos dados locais, a partir das contagens registradas pelo programa em distribuicao_clientes.csv.

8 DISCUSSÃO

A implementação integrou preparação de dados, treinamento centralizado e federado, avaliação preditiva, explicabilidade local e global e visualização. Os resultados também evidenciaram variações de desempenho entre as configurações e entre as sementes, reforçando a importância de controlar o particionamento e os parâmetros de treinamento.

A escolha de Integrated Gradients é coerente com a arquitetura neural utilizada e permite produzir contribuições por característica. Ainda assim, a qualidade de uma explicação não é estabelecida apenas pelo valor de atribuição. Estabilidade, fidelidade a perturbações e plausibilidade no domínio dos sensores exigem testes específicos. Em particular, mudanças na distribuição das atividades podem alterar o conjunto de amostras e, portanto, modificar as importâncias globais mesmo quando os parâmetros do modelo são mantidos.

Outra questão é a distinção entre simulação de aprendizado federado e implantação federada. No protótipo, cada cliente corresponde a um subconjunto de índices executado sequencialmente em um processo local, sem custos de rede mensurados. A padronização de dados utiliza estatísticas globais da partição de treinamento. Uma aplicação real demandaria tratamento de conectividade, falhas, participação parcial, mecanismos de proteção de atualizações e política de armazenamento, aspectos que não foram implementados.

Uma ampliação da avaliação inclui a execução sobre o UCI HAR, a escolha de hiperparâmetros com validação, novas repetições, medidas de desbalanceamento entre clientes e comparações de atribuições em amostras comuns. Essas etapas também permitiriam discutir os resultados em relação a estudos empíricos do domínio de sensores.

9 AMEAÇAS À VALIDADE E LIMITAÇÕES

Validade interna: as métricas podem ser afetadas pelo tamanho das partições, pela inicialização, pelos hiperparâmetros e pelo número de atualizações, além do grau Não-IID. Não houve busca sistemática de hiperparâmetros. Como cada semente também altera a geração dos registros, a dispersão combina fatores de dados e treinamento. Validade de construção: a média absoluta de Integrated Gradients quantifica atribuições, sem constituir

uma explicação causal. O índice Top-5 depende das observações analisadas e do número de características.

Validade externa: o gerador de dados não reproduz integralmente a dinâmica temporal, o ruído e as condições de aquisição de sensores físicos. O UCI HAR também corresponde a condições específicas de coleta e a características previamente extraídas dos sinais. Reprodutibilidade: versões das bibliotecas e diferenças numéricas de hardware podem afetar resultados. Aspectos éticos: aplicações com dados de pessoas requerem governança, definição de finalidade e tratamento adequado das informações.

10 CONSIDERAÇÕES FINAIS

O trabalho reuniu um artigo metodológico e uma aplicação computacional para analisar explicabilidade local e global sob partições IID e Não-IID. Foram implementados treinamento centralizado, FedAvg, FedProx, avaliação por acurácia e Macro-F1, Integrated Gradients, índices de concordância entre clientes e dashboard. A execução das três sementes e os testes automatizados permitiram verificar o funcionamento dos componentes e organizar os resultados comparativos.

A aplicação constitui uma base reproduzível para ampliar o estudo com observações provenientes de sensores. O protocolo documentado estabelece as etapas necessárias para avaliar hipóteses sobre heterogeneidade estatística, desempenho de classificação e consistência de explicações em conjuntos de dados reais.

REFERÊNCIAS

ANGUITA, Davide et al. A public domain dataset for human activity recognition using smartphones. In: EUROPEAN SYMPOSIUM ON ARTIFICIAL NEURAL NETWORKS, COMPUTATIONAL INTELLIGENCE AND MACHINE LEARNING (ESANN), 2013. Proceedings [...]. 2013. p. 437–442.

KAIROUZ, Peter et al. Advances and open problems in federated learning. Foundations and Trends in Machine Learning, v. 14, n. 1–2, p. 1–210, 2021. DOI: 10.1561/2200000083.

LI, Tian et al. Federated optimization in heterogeneous networks. Proceedings of Machine Learning and Systems, v. 2, p. 429–450, 2020. Disponível em: https://arxiv.org/abs/1812.06127.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30, 2017. Proceedings [...]. 2017. Disponível em: https://arxiv.org/abs/1705.07874.

MCMAHAN, H. Brendan et al. Communication-efficient learning of deep networks from decentralized data. In: INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE AND STATISTICS (AISTATS), 20, 2017. Proceedings [...]. PMLR, v. 54, p. 1273–1282, 2017. Disponível em: https://proceedings.mlr.press/v54/mcmahan17a.html.

SUNDARARAJAN, Mukund; TALY, Ankur; YAN, Qiqi. Axiomatic attribution for deep networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 34, 2017. Proceedings [...]. PMLR, v. 70, p. 3319–3328, 2017. Disponível em: https://proceedings.mlr.press/v70/sundararajan17a.html.

UNIVERSITY OF CALIFORNIA, IRVINE. Human Activity Recognition Using Smartphones. UCI Machine Learning Repository, 2013. Disponível em: https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones.

APÊNDICE A — PROTOCOLO DE REPRODUÇÃO

1. Criar um ambiente virtual de Python 3.10 ou superior. 2. Instalar as dependências de requirements.txt e o projeto com pip install -e . 3. Executar o modo sintético com as sementes 42, 43 e 44, conforme os comandos das seções técnicas. 4. Rodar pytest -q. 5. Iniciar streamlit run app.py e selecionar o diretório de resultados. 6. Obter o UCI HAR no repositório oficial e executar o carregador com --mode uci e --dataset-path. 7. Salvar cada execução em diretório separado. 8. Consolidar médias e desvios-padrão após verificar a integridade dos arquivos.

As linhas de comando completas estão no README do arquivo ZIP. O arquivo de configuração exportado permite auditar os parâmetros de cada execução. Caso a investigação venha a envolver dispositivos físicos, novas etapas de implementação e validação de privacidade, desempenho de rede e qualidade dos sinais serão necessárias.

APÊNDICE B — FICHA DE REVISÃO BIBLIOGRÁFICA

Item a registrar	Informação a coletar
Identificação	Título, autores, ano, evento ou periódico e DOI/URL.
Pergunta de pesquisa	Fenômeno investigado e hipótese do estudo.
Dados	Origem, participantes e natureza dos sinais.
Não-IID	Tipo de heterogeneidade e como foi construída/medida.
Método	Arquitetura, estratégia federada e baselines.
Explicabilidade	Método XAI, nível local/global, base de comparação.
Resultados	Métricas, número de repetições, dispersão e limitações.
Contribuição para o projeto	Que decisão experimental o estudo informa.

APÊNDICE C — STATUS DOS ENTREGÁVEIS

A versão entregue inclui preparação e separação de dados, partições Dirichlet, carregador compatível com UCI HAR, treinamento centralizado, FedAvg e FedProx, métricas de acurácia e Macro-F1, Integrated Gradients, exportações CSV, figuras, dashboard e testes automatizados. A implantação em dispositivos físicos e mecanismos formais de privacidade

não integram esta versão. A execução com dados do UCI HAR e uma análise ampliada da estabilidade das explicações compõem possibilidades de extensão.

PARTE II — CADERNO TÉCNICO DA APLICAÇÃO

Este caderno integra o artigo ao desenvolvimento computacional e contém especificação funcional, estrutura de arquivos, procedimento de execução, exemplos de código, registros dos resultados gerados e critérios de verificação. O código-fonte integral executável acompanha o arquivo ZIP da aplicação; os trechos reproduzidos aqui documentam as operações essenciais e não devem ser tratados como programas independentes de seus módulos.

1 IDENTIFICAÇÃO E ESCOPO DO PROTÓTIPO

Identificação	Descrição
Nome da aplicação	Federated XAI Lab
Natureza	Protótipo acadêmico de simulação federada.
Dataset executado	Gerador sintético de características associadas a eixos hipotéticos de sensores.
Dataset compatível	UCI Human Activity Recognition Using Smartphones; arquivos oficiais não distribuídos no ZIP.
Treinamento	Modelo MLP centralizado, FedAvg e FedProx.
Explicabilidade	Integrated Gradients; atribuições locais e agregação global.
Resultados	Arquivos CSV, JSON, gráficos PNG e painéis para inspeção.
Limites	Sem sensores físicos, servidor em rede, garantia criptográfica ou privacidade diferencial.

A aplicação permite configurar experimentos comparativos e identificar as características com maior atribuição nas previsões da rede neural. Os dados podem ser gerados pelo módulo sintético ou carregados a partir de um conjunto de características previamente estruturadas.

2 ARQUITETURA E ORGANIZAÇÃO DO PROJETO

A implementação tem cinco etapas encadeadas: (i) carregar ou gerar observações; (ii) dividir treinamento, validação e teste por participantes; (iii) distribuir índices de treinamento entre clientes; (iv) treinar e avaliar três métodos; e (v) calcular explicações, exportar resultados e apresentar gráficos. A coordenação das etapas está em experiment.py. O painel Streamlit é um visualizador separado, não uma interface responsável por atualizar os pesos do modelo.

Arquivo / pasta	Função no sistema
src/flxai/data.py	Dados sintéticos, leitura do UCI HAR, divisão por grupos e partição Dirichlet.
src/flxai/models.py	Definição da rede neural MLP para classificação.
src/flxai/federated.py	Atualização local por SGD, FedAvg, FedProx, avaliação e baseline.
src/flxai/explanation.py	Integrated Gradients, médias globais e concordância Top-k.
src/flxai/experiment.py	Execução parametrizada, registro de resultados e figuras.

Arquivo / pasta	Função no sistema
app.py	Dashboard em Streamlit que lê as saídas exportadas.
dashboard_offline.html	Painel navegável com a execução de semente 42.
tests/	Testes automatizados de integridade e comportamento.
results/	CSV, imagens e configurações das execuções sintéticas.
README.md	Manual de instalação e comandos de reprodução.

3 AMBIENTE DE DESENVOLVIMENTO

Ferramenta	Aplicação	Situação no protótipo
Python 3.10+	Ambiente de execução	Utilizado
PyTorch	Rede neural e diferenciação automática	Utilizado
NumPy / Pandas	Vetores, tabelas e exportação CSV	Utilizados
scikit-learn	Separações por grupos, normalização e métricas	Utilizado
Matplotlib	Produção de gráficos	Utilizado
Streamlit	Dashboard de resultados	Utilizado
pytest	Testes automatizados	Utilizado
Flower	Coordenação federada distribuída em outro framework	Não utilizado
SHAP	Outra técnica possível de XAI	Não implementada

Os clientes são representados por partições locais processadas sequencialmente no mesmo computador. A implementação de FedAvg e FedProx utiliza PyTorch, sem dependência de Flower nem comunicação de rede entre dispositivos.

4 CONJUNTO DE DADOS E PRÉ-PROCESSAMENTO

O gerador utilizado nos experimentos constrói 24 participantes artificiais, cada um com 75 observações, totalizando 1.800 registros. Cada registro possui 12 características sintéticas de médias e desvios dos eixos acc_x, acc_y, acc_z, gyro_x, gyro_y e gyro_z. Os rótulos artificiais correspondem a “parado”, “caminhando”, “correndo” e “subindo_escadas”. Os vetores são construídos a partir de centros de classe, deslocamentos individuais e ruído aleatório.

Partição — semente 42	Registros	Observação
Treinamento	1.050	Participantes não compartilhados com validação ou teste.
Validação	300	Apoio ao registro de desempenho por rodada.

Partição — semente 42	Registros	Observação
Teste	450	Avaliação final das métricas; participantes separados.
Total	1.800	24 participantes artificiais × 75 registros.

A separação usa GroupShuffleSplit para evitar que participantes artificiais apareçam simultaneamente em treino, validação e teste. O StandardScaler ajusta média e desvio-padrão exclusivamente no treino agregado, e transforma os demais conjuntos com esses parâmetros. Esse escalonamento centralizado serve apenas ao benchmark offline, pois um sistema federado com requisito real de confidencialidade deveria calcular estatísticas por procedimento compatível com a arquitetura de privacidade.

```
# Estrutura ilustrativa do gerador presente em data.py
classes = ['parado', 'caminhando', 'correndo', 'subindo_escadas']
features = [f'{eixo}_{estat}' for eixo in eixos for estat in ('media','desvio')]
X, y, sujeitos = criar_registros_sinteticos(seed=42)
train_idx, val_idx, test_idx = separar_por_participante(sujeitos)
scaler = StandardScaler().fit(X[train_idx])
X_normalizado = scaler.transform(X)
```

O bloco anterior expressa o procedimento de forma resumida. As funções exatas, com esses cálculos implementados, estão em src/flxai/data.py no projeto executável.

5 DISTRIBUIÇÃO IID E NÃO-IID ENTRE CLIENTES

O procedimento Dirichlet reparte os índices de cada classe entre seis clientes e verifica a presença de um número mínimo de amostras. Foram utilizados $\alpha = 100$, $\alpha = 0{,}5$ e $\alpha = 0{,}15$. Como a distribuição é amostral, os níveis não constituem definições absolutas de heterogeneidade; as contagens concretas precisam ser examinadas. A opção de partição natural do UCI HAR agrupa participantes, quando o conjunto real estiver disponível.

```
for classe in classes:
    indices = embaralhar(indices_da_classe)
    proporcoes = rng.dirichlet([alpha] * clientes)
    grupos = dividir_indices(indices, proporcoes)
    for cliente, grupo in enumerate(grupos):
        particoes[cliente].extend(grupo)
# Confere se as particoes sao disjuntas e cobrem todo o treino.
```

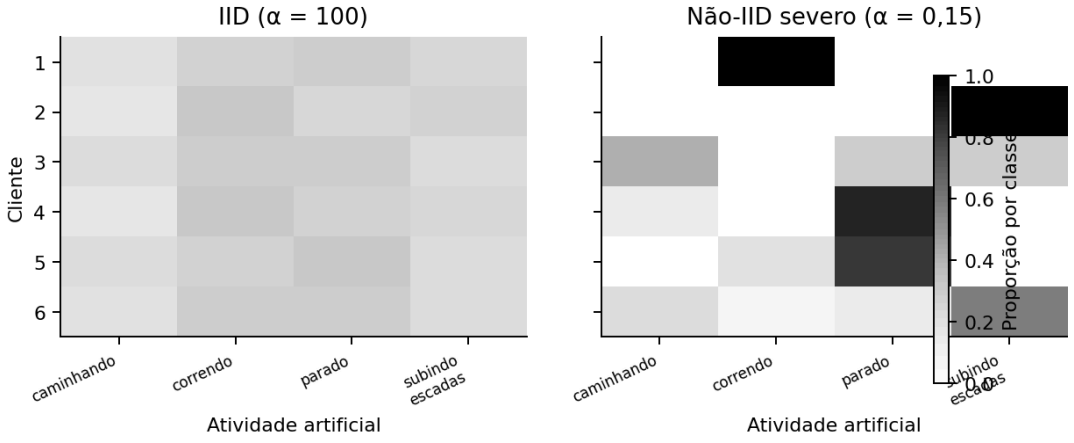


Figura 5 — Distribuição de classes entre clientes.

Fonte: distribuição de treinamento gerada pelo projeto; semente 42.

A separação lógica preserva o protocolo de treinamento local e agregação, mas não realiza mensuração de tráfego, falhas, atrasos ou segurança da comunicação.

6 TREINAMENTO CENTRALIZADO, FEDAVG E FEDPROX

O baseline centralizado treina a mesma arquitetura usando a parte agregada de treinamento. O FedAvg combina modelos treinados individualmente; cada atualização é ponderada pelo número de registros do cliente. O FedProx acrescenta à função de perda uma penalidade proximal definida pelo parâmetro μ e pela distância entre pesos locais e globais. Os métodos utilizam SGD, entropia cruzada, arquitetura compartilhada e sementes controladas.

A atualização pode ser descrita por: w(t+1) = soma_k (n_k / N) · w_k(t+1). Em FedProx, a perda local é acrescida de (μ/2) · ||w − w_global||². A notação resume o código executado, mas não pretende estabelecer identidade de custos computacionais entre os métodos. No baseline centralizado, 15 rodadas equivalem a 15 épocas sobre todos os exemplos; nos métodos federados, cada rodada inclui uma época local por cliente.

```
def weighted_average(models, weights):
    pesos = np.asarray(weights, dtype=np.float64)
    pesos = pesos / pesos.sum()
    estados = [m.state_dict() for m in models]
    agregado = {
        nome: sum(float(pesos[i]) * estado[nome]
                  for i, estado in enumerate(estados))
        for nome in estados[0]
    }
    saida = copy.deepcopy(models[0])
    saida.load_state_dict(agregado)
    return saida
```

A cada rodada: (1) o modelo global inicializa as cópias locais; (2) cada cliente aplica SGD aos próprios registros; (3) o agregador combina os parâmetros; (4) o modelo agregado é

avaliado em validação; (5) o ciclo se repete. Ao final, as métricas são registradas no conjunto de teste.

```
# Trecho representativo da penalidade FedProx em federated.py
loss = F.cross_entropy(model(x_batch), y_batch)
if mu > 0:
    loss = loss + (mu / 2.) * sum(
        ((p - ref)**2).sum()
        for p, ref in zip(model.parameters(), parametros_globais)
    )
loss.backward()
optimizer.step()
```

7 EXPLICABILIDADE LOCAL E GLOBAL

O protótipo implementa Integrated Gradients. Para cada registro de entrada x, parte de uma referência nula no espaço padronizado, interpola 16 pontos entre referência e observação e calcula gradientes do logit da classe prevista. A soma aproximada dos gradientes multiplicada pela diferença da entrada produz uma atribuição por característica. O sinal indica contribuição positiva ou negativa para o logit avaliado; seu módulo é usado para produzir importâncias globais.

```
# Formula operacional simplificada; versao completa em explanation.py
for alpha in torch.linspace(0., 1., steps + 1)[1:]:
    x_pass = (baseline + alpha * (x - baseline))
    x_pass = x_pass.detach().requires_grad_(True)
    logit = modelo(x_pass).gather(1, classe_prevista[:,None]).sum()
    soma_gradientes += torch.autograd.grad(logit, x_pass)[0]
atribuicoes = (x - baseline) * (soma_gradientes / steps)
importancia_global = np.mean(np.abs(atribuicoes), axis=0)
```

As explicações individuais são registradas em atribuicoes_locais.csv. O resumo global, para cada cenário e modelo, fica em importancia_global.csv. Os resumos por cliente são calculados a partir de um número fixo de exemplos locais e armazenados em importancia_por_cliente.csv. A concordância dos conjuntos de cinco características mais relevantes é descrita pelo índice de Jaccard, mas depende das amostras que foram explicadas.

Atributo	**Atribuição local (IG)**	**Observação**
acc_x_media	-0,0083	Valor relativo ao logit previsto.
acc_x_desvio	+0,0184	Valor relativo ao logit previsto.
acc_y_media	+0,0675	Valor relativo ao logit previsto.
acc_y_desvio	+0,1877	Valor relativo ao logit previsto.
acc_z_media	+0,0955	Valor relativo ao logit previsto.
acc_z_desvio	-0,0315	Valor relativo ao logit previsto.
gyro_x_media	-0,0363	Valor relativo ao logit previsto.

Exemplo de atribuições para a primeira observação do conjunto de teste: FedAvg, IID, semente 42.

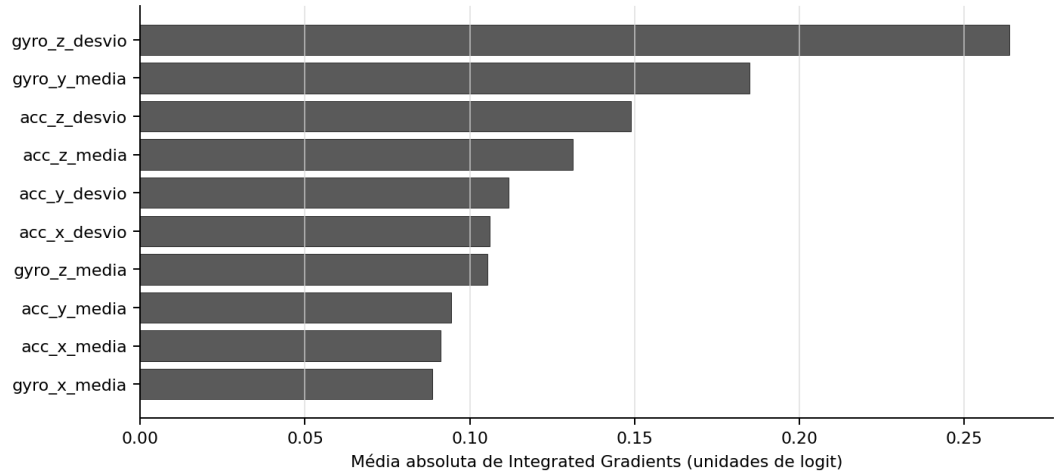


Figura 6 — Importância global das características no FedAvg, cenário Não-IID severo.

Fonte: elaboração própria, a partir da execução com semente 42.

Na configuração representada, gyro_z_desvio, gyro_y_media e acc_z_desvio obtiveram as maiores médias absolutas de atribuição. As importâncias resumem o comportamento do modelo sobre as observações avaliadas.

8 RESULTADOS E ANÁLISE COMPARATIVA

Foram realizadas três execuções completas, com sementes 42, 43 e 44. Em cada execução foram comparados três métodos de treinamento sob três cenários de distribuição, com exportação de métricas, históricos de validação, atribuições e gráficos. A Tabela a seguir consolida os resultados registrados nos arquivos CSV.

Cenário	Modelo	Macro-F1 (média ± DP)
IID	Centralizado	0,952 ± 0,021
IID	FedAvg	0,404 ± 0,119
IID	FedProx	0,398 ± 0,120
Não-IID moderado	Centralizado	0,952 ± 0,021
Não-IID moderado	FedAvg	0,614 ± 0,046
Não-IID moderado	FedProx	0,605 ± 0,036
Não-IID severo	Centralizado	0,952 ± 0,021
Não-IID severo	FedAvg	0,727 ± 0,170
Não-IID severo	FedProx	0,706 ± 0,159

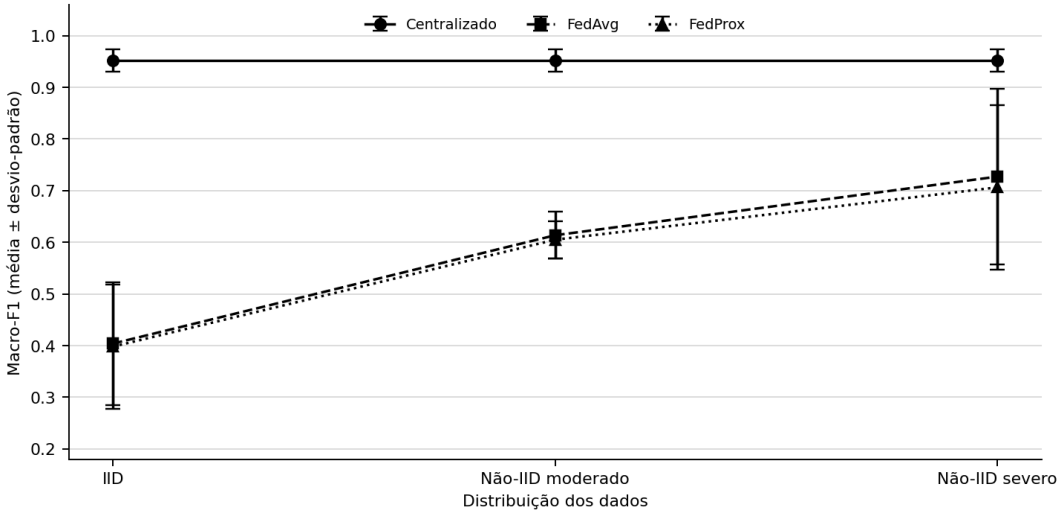


Figura 7 — Comparação de Macro-F1 nas três execuções.

Fonte: elaboração própria, a partir dos CSVs das sementes 42, 43 e 44.

O treinamento centralizado apresentou Macro-F1 média de 0,952 em todos os cenários. O FedAvg atingiu médias de 0,404, 0,614 e 0,727, respectivamente para IID, Não-IID moderado e Não-IID severo. Houve variação relevante entre sementes: no cenário severo, a semente 44 registrou 0,532, enquanto a semente 43 registrou 0,838. Os números apontam sensibilidade do treinamento às condições de execução.

Distribuição	Modelo	Jaccard Top-5 (média ± DP)
IID	FedAvg	0,732 ± 0,160
IID	FedProx	0,732 ± 0,160
Não-IID moderado	FedAvg	0,638 ± 0,127
Não-IID moderado	FedProx	0,650 ± 0,140
Não-IID severo	FedAvg	0,519 ± 0,114
Não-IID severo	FedProx	0,503 ± 0,115

Os índices de concordância entre clientes foram calculados a partir de explicações sobre subconjuntos locais de treinamento. A comparação expressa diferenças nas entradas e nas atribuições obtidas, que podem ser examinadas posteriormente sobre amostras de referência comuns.

9 REGISTROS PRODUZIDOS E SIGNIFICADO

Arquivo de saída	Conteúdo e uso
metricas.csv	Acurácia, Macro-F1, método, cenário, semente e origem.
historico_validacao.csv	Evolução de acurácia e Macro-F1 ao longo das rodadas.
distribuicao_clientes.csv	Contagem de classe por cliente em cada cenário.
importancia_global.csv	Rankings e média absoluta das atribuições.

Arquivo de saída	Conteúdo e uso
atribuicoes_locais.csv	Valores de contribuição de atributos por registro individual.
importancia_por_cliente.csv	Importância calculada sobre registros locais dos clientes.
concordancia_entre_clientes.csv	Similaridade média Top-5 entre pares de clientes.
concordancia_top5.csv	Sobreposição Top-5 entre tipos de treinamento.
config.json	Parâmetros e sementes da execução.
dataset_info.json	Origem, dimensões e ressalvas sobre o dataset.
resumo_sintetico_3_sementes.csv	Consolidação de médias e desvios-padrão dos três ensaios.

Os resultados estão no ZIP em results/demonstracao (semente 42), results/demonstracao_seed_43 e results/demonstracao_seed_44. A consolidação das três execuções está na pasta results. A interface HTML offline demonstra somente a semente 42, enquanto o painel Streamlit pode ler qualquer diretório de execução selecionado.

10 INSTALAÇÃO E EXECUÇÃO REPRODUZÍVEL

Os comandos abaixo devem ser executados no terminal, no diretório raiz do projeto extraído. As instalações podem variar de acordo com sistema operacional, versão de Python e permissões locais. O dataset UCI HAR não é baixado automaticamente nem acompanha a entrega.

```
python -m venv .venv
# Windows: .venv\Scripts\activate
# Linux/macOS: source .venv/bin/activate
python -m pip install -r requirements.txt
python -m pip install -e .
python -m pip install pytest
pytest -q
```

Os comandos seguintes reproduzem os três experimentos com a mesma configuração e sementes distintas:

```
python -m flxai.experiment --mode synthetic --seed 42 --clients 6 --rounds 15 --lr 0.07 --mu 0.3 --xai-samples 50 --ig-steps 16
--output-dir results/demonstracao
python -m flxai.experiment --mode synthetic --seed 43 --clients 6 --rounds 15 --lr 0.07 --mu 0.3 --xai-samples 50 --ig-steps 16
--output-dir results/demonstracao_seed_43
python -m flxai.experiment --mode synthetic --seed 44 --clients 6 --rounds 15 --lr 0.07 --mu 0.3 --xai-samples 50 --ig-steps 16
--output-dir results/demonstracao_seed_44
streamlit run app.py
```

Para executar com UCI HAR real, baixar o dataset oficial da UCI, extrair a pasta “UCI HAR Dataset” em data/ e executar:

```
python -m flxai.experiment --mode uci --dataset-path "data/UCI HAR Dataset" --output-dir results/uci_seed_42 --rounds 15
--clients 6 --seed 42 --include-natural
```

A execução com UCI HAR depende da obtenção do conjunto oficial. Seu uso permite manter o teste por participante e comparar os resultados sob a mesma estrutura experimental.

11 VERIFICAÇÃO DE FUNCIONAMENTO

Item verificado	Evidência observada
Leitura / geração de dados	Vetores de 12 características com grupos e rótulos definidos.
Separação por participantes	Grupos de treino, validação e teste disjuntos.
Particionamento federado	Cobertura integral dos índices com subconjuntos disjuntos.
Agregação federada	Teste de média ponderada dos parâmetros.
Explicabilidade	Teste de formato e valores produzidos por IG.
Treinamento de uma rodada	Execução básica de FedAvg/FedProx.
Conjunto de testes	6 testes passaram no ambiente de preparação.
Execuções concluídas	Sementes 42, 43 e 44.

O conjunto automatizado verifica integridade dos dados, particionamento, agregação, atribuições e funcionamento básico do treinamento. As instruções de reprodução permitem executar o projeto em ambiente Python compatível.

12 LIMITAÇÕES, VALIDADE E CONTINUIDADE EXPERIMENTAL

A padronização a partir do treino agregado, as três sementes e a ausência de ajuste sistemático de hiperparâmetros. Os orçamentos de treinamento centralizado e federado não foram igualados. O método Integrated Gradients também depende da referência escolhida, do número de passos e da classe explicada.

A análise entre clientes pode ser ampliada com um mesmo conjunto de observações de referência, testes de perturbação, medidas de estabilidade de rankings e avaliações por classe. A execução com UCI HAR representa uma continuidade possível do experimento.

O projeto integra código executável, métricas registradas, figuras, documentação de reprodução e interface de exploração dos resultados.